ИТМО
ВЫСШАЯ ШКОЛА
ЦИФРОВОЙ КУЛЬТУРЫ

Данные с гибкой структурой и NoSQL

Данные как основа ИИ · Тема 09

- JSON-документы, вложенные структуры и API
- Преобразование документов в связанные таблицы
- Выбор хранения и проверка результата ИИ

Каталог товаров → документы → запросы → таблицы → решение

Два вопроса к одному каталогу

Карточка товара и аналитический отчёт требуют разного представления.

- Карточка: товар, размеры и последние отзывы вместе
- Отчёт: средняя цена по категориям, один вес на товар
- Обновление: где менять цену и где модерировать отзыв?

? Должен ли отзыв создавать ещё одну строку товара?

Что ограничивает плоскую таблицу

Один товар может иметь несколько отзывов и свой набор характеристик.

- Повторить товар на каждый отзыв — повторяется цена
- review_1, review_2… — заранее ограничить число отзывов
- Связанные таблицы — явные ключи и сборка через JOIN

Реляционная модель может хранить эти данные. Сравниваем удобство операций.

JSON: объекты и массивы

Объект — именованные поля; массив — упорядоченный набор элементов.

```
{
  "id": 2, "price": 19.99,
  "brand": null,
  "dimensions": {"width": 9.26},
  "reviews": [{"rating": 5, "verified": true}]
}
```

Типы и пути к значениям

Строка "19.99" и число 19.99 — разные значения.

- Типы JSON: object, array, string, number, boolean, null
- dimensions.width — поле вложенного объекта
- reviews[0].rating — первый отзыв в JSON-тренажёре

? Что вернёт путь reviews[0].rating при reviews: []?

missing, null, пустое значение

Отсутствие ключа и явное пустое значение нужно различать.

- Нет brand — ключ не передан
- brand: null — ключ есть, значение null
- reviews: [] — массив существует, но отзывов нет

0, false и пустая строка не равны отсутствующему полю.

API, JSON и база данных

Это три разных уровня работы с данными.

- API определяет способ запросить данные сервиса
- JSON задаёт формат передаваемого ответа
- СУБД хранит данные, выполняет запросы и ограничения

Получение JSON не требует выбирать MongoDB.

GET-запрос к каталогу

Параметры управляют страницей, а не содержимым всей базы.

```
GET https://dummyjson.com/products?limit=10&skip=0

{ "products": [ ... ],
  "total": 194, "skip": 0, "limit": 10 }
```

? Сколько товаров уже находится в этом ответе?

Проверка полноты и воспроизводимости

Сначала определите, сколько данных требуется задаче.

- Сохранить URL, дату, ответ и режим live/snapshot
- Проверить products.length, total, limit и skip
- Для полного каталога — все страницы и уникальные id

В домашней нужен свой блок из 10 товаров, а не весь каталог.

Документная база: основные понятия

Документ может содержать вложенные объекты и массивы.

- Документ — сведения о товаре
- Коллекция — набор документов
- MongoDB хранит BSON: есть ObjectId и тип даты

JSON-файл и база MongoDB — разные способы хранения.

Гибкая структура требует правил

Разные поля допустимы; случайные типы и потерянные ключи мешают анализу.

- id — устойчивый идентификатор; price — число
- reviews — массив, обязательность полей описана
- Валидация схемы и уникальные индексы задают ограничения

? Можно ли смешать price: 19.99 и price: "дёшево" без последствий?

NoSQL — несколько семейств моделей

Документная модель — один из подходов.

- Документы: карточки с вложенными сведениями
- Ключ — значение: значение по известному ключу
- Графы: связи и пути; ширококолонночные: доступ по ключам разделов

Сравнивайте запросы, связи и обновления. Обещания «всегда быстрее» нет.

Фильтр: категория и цена

Условия по разным полям фильтра соединяются логическим И.

```
db.collection.find({
  category: "fragrances",
  price: { $gte: 70 }
})
```

Учебная выборка: 3 товара — id 7, 8, 10.

Путь и наличие поля в MongoDB

Путь через точку обращается к вложенному значению.

```
{ "dimensions.width": { $gt: 20 } }

{ brand: null }                 // 8 документов
{ brand: { $exists: false } }   // 4 документа
{ brand: { $exists: true } }    // 8 документов
```

Два условия могут найти разные отзывы

В одном массиве высокий рейтинг и verified:true могут быть у разных элементов.

```
"reviews": [
  { "rating": 5, "verified": false },
  { "rating": 2, "verified": true }
]
```

? Есть ли здесь подтверждённый отзыв с рейтингом не меньше 4?

$elemMatch: один подходящий элемент

Оба условия должен выполнить один и тот же отзыв.

```
{ reviews: { $elemMatch: {
    rating: { $gte: 4 },
    verified: true
} } }
```

Независимые условия: 9 товаров. $elemMatch: 3 — id 2, 6, 10.

Что меняет $unwind

Для каждого отзыва появляется отдельная строка.

- До: 12 товаров, 18 отзывов
- После: 18 строк, только 9 уникальных товаров
- 3 товара без отзывов исчезли из результата

Без preserveNullAndEmptyArrays пустые массивы не дают строк.

Цена не менялась, средняя изменилась

Единица наблюдения определяет вес каждого товара.

- По 12 товарам: 407,24
- По 18 строкам отзывов: 669,38
- Цена повторилась столько раз, сколько у товара отзывов

? Почему AVG(DISTINCT price) тоже не исправляет расчёт?

Две связанные таблицы

Сохраняем разные единицы наблюдения отдельно.

- products: 12 строк, одна на каждый id
- reviews: 18 строк; product_id ссылается на products.id
- review_index — позиция в массиве, не постоянный id отзыва

CSV — выбранная аналитическая проекция; полный JSON сохраняем.

Группируем товары по категориям

Не раскрываем reviews, если вопрос относится к ценам товаров.

```
db.collection.aggregate([
  { $group: { _id: "$category",
      count: { $sum: 1 },
      avg_price: { $avg: "$price" }
  } }
])
```

Вложение или отдельная коллекция?

Решение зависит от совместного чтения и независимых обновлений.

- Карточка: можно вложить пять последних отзывов
- Вся растущая история: отдельные reviews с product_id
- Дублирование требует согласованного обновления копий

Рост массива, частота записи и ограничения важнее формата ответа API.

ИИ: что поручить и что проверить

Попросите структуру или преобразование с явными ограничениями.

- Сохранить все id, типы и товары без отзывов
- Проверить ключи, число строк и контрольный агрегат
- Не добавлять verified в исходные варианты домашней

? Правильный JSON доказывает правильность результата?

Маршрут практики и домашней

Одна тема, два набора с разным назначением.

- 09·1: JSON → две таблицы, проверка потерь и среднего
- 09·2: запросы и выбор структуры; учебные 12 товаров
- ЛР: свой raw-вариант из 10 товаров, настоящий MongoDB

Учебные изменения описаны в паспорте. Не смешивайте training и raw.

Перед выбором модели

Ответьте на четыре вопроса о будущей работе с данными.

- Что читаем и изменяем вместе?
- Что растёт независимо и какие связи нужно проверять?
- Какая единица наблюдения нужна в отчёте?
- Как воспроизвести результат и проверить помощь ИИ?